

Entrega Lista 3 - IA

Aluno: Gabriel Ferreira Pereira

Link colab: [🔗 AD-Titanic - codifica treina e avalia.ipynb](#)

QUESTÃO 01 – ANÁLISE DA BASE TITANIC

O objetivo foi identificar padrões de sobrevivência dos passageiros do Titanic utilizando Árvore de Decisão e Random Forest. Foram comparados dois métodos de imputação, duas técnicas de balanceamento e dois otimizadores de hiperparâmetros.

1. PREPARAÇÃO DOS DADOS


A base possui 1.309 passageiros: 809 não sobreviveram (61,8%) e 500 sobreviveram (38,2%). Portanto, os sobreviventes formam a classe minoritária. Foram utilizados pclass, sex, age, sibsp, parch, fare e embarked, tendo survived como variável-alvo. Os atributos boat e body foram retirados por revelarem informações posteriores ao acidente; cabin e home.dest, pela grande quantidade de ausências; e name e ticket, por serem identificadores.

Após a codificação, os dados foram divididos de forma estratificada em 80% para treino e 20% para teste, com random_state=42. O treino ficou com 1.047 passageiros, sendo 647 não sobreviventes e 400 sobreviventes, enquanto o teste ficou com 262 passageiros. Imputação, padronização e balanceamento foram ajustados somente no treino, evitando vazamento de informações. O conjunto de teste não foi balanceado.

2. COMPARAÇÃO DOS MÉTODOS DE IMPUTAÇÃO

Foram comparados KNNImputer e MissForest, este último implementado com IterativeImputer e ExtraTreesRegressor. No treino, age possuía 209 valores ausentes e fare possuía apenas um.

Figura 1 – Distribuições dos atributos antes e depois da imputação.



imputador	atributo	ausentes_antes	media_antes	media_depois	mediana_antes	mediana_depois	desvio_antes	desvio_depois	KS
KNN	age	209	29.60431980906921	29.771671005264157	28.0	28.0	14.362728470961727	13.559301887550223	0.040912437627224504
KNN	fare	1	32.166837667304016	32.15303377268386	13.81665	13.8583	48.91581962119263	48.894471890681004	0.0005478641516049681
KNN	embarked	0	1.492836676217765	1.492836676217765	2.0	2.0	0.8120132164808672	0.8120132164808672	0.0
MissForest	age	209	29.60431980906921	29.302129225028693	28.0	28.0	14.362728470961727	13.548742220510286	0.02754089990038592
MissForest	fare	1	32.166837667304016	32.14231406399236	13.81665	13.775	48.91581962119263	48.898870656520266	0.0009377608061638369
MissForest	embarked	0	1.492836676217765	1.492836676217765	2.0	2.0	0.8120132164808672	0.8120132164808672	0.0

Na idade, a média observada era 29,604 anos. Depois da imputação, passou para 29,772 com KNN e 29,302 com MissForest, mantendo a mediana em 28 anos nos dois métodos. Na tarifa, a média original era 32,167 e passou para 32,153 com KNN e 32,142 com MissForest, uma alteração muito pequena.

Os dois métodos conservaram distribuições próximas às originais, mas o MissForest apresentou menor KS médio: 0,0095, contra 0,0138 do KNN. Em age, atributo com mais ausências, o KS foi 0,028 para MissForest e 0,041 para KNN. Assim, o MissForest preservou melhor a distribuição e foi adotado como método principal, embora ambos tenham sido avaliados na modelagem.

3. COMPARAÇÃO DOS MÉTODOS DE BALANCEAMENTO

Antes do balanceamento, o treino possuía 647 não sobreviventes e 400 sobreviventes. Depois do SMOTE, passou a ter 647 exemplos de cada classe. Com RandomUnderSampling, passou a ter 400 exemplos de cada classe.

O SMOTE criou exemplos sintéticos da classe sobrevivente, enquanto o RandomUnderSampling reduziu a classe majoritária. Em média, o SMOTE obteve precisão de 0,766, recall de 0,776 e F1 de 0,771. O RandomUnderSampling obteve precisão de 0,752, recall de 0,789 e F1 de 0,770. Portanto, a subamostragem favoreceu ligeiramente o recall, mas o SMOTE apresentou maior precisão e o melhor F1 médio.

4. OTIMIZAÇÃO DOS HIPERPARÂMETROS

Foram utilizados RandomizedSearchCV e Optuna com TPE. Ambos realizaram 15 tentativas, com validação cruzada estratificada de três divisões e F1 dos sobreviventes como métrica de seleção.


Melhores resultados encontrados:

- Árvore de Decisão com Random Search: KNN + SMOTE, F1-CV de 0,7363 em 1,72 segundo, usando profundidade 5, mínimo de 9 exemplos para divisão, mínimo de 2 por folha e critério gini.
- Árvore de Decisão com Optuna: MissForest + SMOTE, F1-CV de 0,7413 em 8,66 segundos, usando profundidade 4, mínimo de 3 exemplos para divisão, mínimo de 6 por folha e critério gini.
- Random Forest com Random Search: MissForest + SMOTE, F1-CV de 0,7459 em 26,06 segundos, usando 237 árvores, profundidade 8, mínimo de 13 exemplos para divisão, mínimo de 2 por folha, max_features=sqrt e critério log_loss.
- Random Forest com Optuna: MissForest + SMOTE, F1-CV de 0,7442 em 23,61 segundos, usando 166 árvores, profundidade 6, mínimo de 2 exemplos para divisão, mínimo de 2 por folha, max_features=sqrt e critério entropy.

Na média de todas as buscas, o Optuna obteve F1-CV de 0,7355 e o Random Search, 0,7352. A diferença de 0,0003 não foi significativa. Como o Random Search também apresentou menor tempo médio, 12,77 segundos contra 13,45 segundos, ele ofereceu a melhor relação entre tempo e qualidade neste experimento.

5. COMPARAÇÃO DOS MODELOS

Figura 2 – Comparação do F1 dos modelos e técnicas de balanceamento.




Resultados médios:

- Árvore de Decisão: F1 = 0,7692.
- Random Forest: F1 = 0,7717.
- KNN: F1 = 0,7629.
- MissForest: F1 = 0,7780.
- SMOTE: F1 = 0,7709.
- RandomUnderSampling: F1 = 0,7700.

O Random Forest apresentou F1 médio ligeiramente maior que a Árvore de Decisão. A melhor configuração, selecionada pela validação cruzada, foi Random Forest + MissForest + SMOTE + Random Search. No teste, ela alcançou acurácia de 0,8359, precisão de 0,7767, recall de 0,8000 e F1 de 0,7882 para os sobreviventes. Assim, o Random Forest apresentou a melhor generalização entre as combinações avaliadas.

6. ÁRVORE DE DECISÃO E PADRÕES ENCONTRADOS

Figura 3 – Visualização da melhor Árvore de Decisão.




A melhor árvore foi obtida com MissForest, SMOTE e Optuna. As regras completas foram extraídas pelo notebook com `export_text`, enquanto a figura permite observar os caminhos de decisão. Os principais padrões foram:

- Mulheres, principalmente da primeira e segunda classes, apresentaram maior tendência de sobrevivência.
- Meninos com até aproximadamente 8,7 anos apresentaram maior chance de sobrevivência, desde que não estivessem acompanhados por muitos irmãos ou cônjuges.
- Homens adultos da segunda ou terceira classe apresentaram forte tendência de mortalidade; entre os homens da primeira classe, passageiros mais jovens tiveram resultado mais favorável.

Portanto, sexo, idade e classe social foram os fatores mais relevantes nas regras da árvore.

7. MATRIZ DE CONFUSÃO DO MELHOR MODELO

Figura 4 – Matriz de confusão do melhor modelo.



O melhor modelo classificou corretamente 139 não sobreviventes e 80 sobreviventes. Houve 23 falsos positivos e 20 falsos negativos. Esses resultados correspondem a 83,59% de acurácia e recall de 80% para os sobreviventes.

8. INTERPRETABILIDADE

A Árvore de Decisão permite explicar cada previsão por uma sequência de condições sobre os atributos. No Random Forest, a decisão resulta do voto de diversas árvores treinadas com diferentes amostras e subconjuntos de atributos. Essa diversidade reduz a variância e tende a melhorar a generalização, mas impede que o conjunto seja representado por uma única sequência simples de regras. Por isso, o Random Forest apresentou desempenho ligeiramente melhor, enquanto a árvore individual permaneceu mais interpretável.

CONCLUSÃO

Os resultados mostram que o pré-processamento e a escolha do modelo influenciaram o desempenho. O MissForest preservou melhor as distribuições e alcançou F1 médio de 0,7780, superior ao 0,7629 do KNN. No balanceamento, o SMOTE apresentou melhor precisão e F1 médio de 0,7709, enquanto o RandomUnderSampling produziu recall um pouco maior e F1 de 0,7700. Entre os otimizadores, não houve diferença relevante de qualidade, mas o Random Search foi ligeiramente mais rápido em média.

O Random Forest obteve F1 médio de 0,7717, contra 0,7692 da Árvore de Decisão. A melhor combinação foi Random Forest + MissForest + SMOTE + Random Search, com acurácia de 83,59%, precisão de 77,67%, recall de 80,00% e F1 de 78,82% no teste. A Árvore de Decisão facilitou a identificação de padrões relacionados principalmente a sexo, idade e classe, enquanto o Random Forest ofereceu a melhor capacidade preditiva ao custo de menor interpretabilidade.