Lista 6 — Inteligência Artificial

Autor: Gabriel Ferreira Pereira

Professora: Cristiane Neri Nobre

Questão 1 — Uma época de backpropagation para XOR

Convenções e fórmulas

Ordem das instâncias: (0,0), (0,1), (1,0), (1,1). Taxa de aprendizado: $\eta = 0{,}5$.

Usa-se a sigmoide em todos os neurônios. O bias equivale a uma entrada constante 1.

Como o enunciado não define o limiar, adota-se classe 1 quando $\hat{y} \geq 0{,}5$ e classe 0 caso contrário.

Os pesos são ajustados somente nas classificações incorretas, conforme solicitado.

A perda adotada para obter os gradientes é $E = (t - \hat{y})^2/2$.

Notação dos pesos: w11 liga x1 a h1; w21 liga x2 a h1;

w12 liga x1 a h2; w22 liga x2 a h2; v1 e v2 ligam h1 e h2 à saída.

b1, b2 e by são os respectivos pesos de bias.

Propagação:

$z1 = w11 \cdot x1 + w21 \cdot x2 + b1$; $h1 = \sigma(z1)$

$z2 = w12 \cdot x1 + w22 \cdot x2 + b2$; $h2 = \sigma(z2)$

$zy = v1 \cdot h1 + v2 \cdot h2 + by$; $\hat{y} = \sigma(zy)$

$\sigma(z) = 1/(1 + \exp(-z))$; $\sigma'(z) = \sigma(z) \cdot (1 - \sigma(z))$

Erros e sinais de ajuste (deltas):

$erro_y = t - \hat{y}$; $\delta y = erro_y \cdot \sigma'(zy)$

$erro_h1 = \delta y \cdot v1$; $\delta h1 = erro_h1 \cdot \sigma'(z1)$

$erro_h2 = \delta y \cdot v2$; $\delta h2 = erro_h2 \cdot \sigma'(z2)$

Os neurônios ocultos não têm alvo próprio: seus erros são propagados a partir da saída.

Aqui, “erro” é o sinal antes da derivada de ativação e “delta” é o sinal depois dela.

Assim ficam registrados ambos os valores, independentemente da nomenclatura usada em aula.

Gradientes e atualização:

$\partial E/\partial peso = -\delta_destino \cdot ativação_origem$

$peso_novo = peso_antigo - \eta \cdot \partial E/\partial peso$

$= peso_antigo + \eta \cdot \delta_destino \cdot ativação_origem$

Para os biases, $ativação_origem = 1$. Todos os deltas usam os pesos anteriores

à atualização da instância; depois, os nove parâmetros são atualizados simultaneamente.

Na instância correta, calculam-se erros e derivadas para exibição, mas a variação aplicada é zero.

Os cálculos preservam a precisão completa; os números exibidos têm nove casas decimais.

Pesos iniciais:

Parâmetro	Valor
w11	0.100000000
w21	0.300000000
b1	0.100000000
w12	0.200000000
w22	0.400000000
b2	-0.100000000
v1	0.200000000
v2	-0.300000000

by	0.100000000

Instância 1 — x1 = 0, x2 = 0, alvo = 0

1. Propagação e saída

z1 = (0.100000000 × 0) + (0.300000000 × 0) + (0.100000000) = 0.100000000

h1 = σ(0.100000000) = 0.524979187

z2 = (0.200000000 × 0) + (0.400000000 × 0) + (-0.100000000) = -0.100000000

h2 = σ(-0.100000000) = 0.475020813

zy = (0.200000000 × 0.524979187) + (-0.300000000 × 0.475020813) + (0.100000000) = 0.062489594

ŷ = σ(0.062489594) = 0.515617317; classe = 1; alvo = 0.

Classificação incorreta: atualizar os pesos.

2. Derivadas da sigmoide

Neurônio	Cálculo: saída × (1 − saída)	Derivada
h1	0.524979187 × (1 – 0.524979187)	0.249376040
h2	0.475020813 × (1 – 0.475020813)	0.249376040
y	0.515617317 × (1 – 0.515617317)	0.249756099

3. Erros e deltas

erro_y = 0 – (0.515617317) = -0.515617317

δy = (-0.515617317) × 0.249756099 = -0.128778570

erro_h1 = (-0.128778570) × (0.200000000) = -0.025755714

δh1 = (-0.025755714) × 0.249376040 = -0.006422858

erro_h2 = (-0.128778570) × (-0.300000000) = 0.038633571

δh2 = (0.038633571) × 0.249376040 = 0.009634287

Perda E = $(t - \hat{y})^2/2$ = 0.132930609.

4. Gradientes e pesos após a instância

Δ aplicado = –0,5 × gradiente se a classe estiver incorreta; caso contrário, Δ aplicado = 0.

Peso	Antes	∂E/∂peso	Δ aplicado	Depois
w11	0.100000000	0.000000000	-0.000000000	0.100000000
w21	0.300000000	0.000000000	-0.000000000	0.300000000
b1	0.100000000	0.006422858	-0.003211429	0.096788571
w12	0.200000000	-0.000000000	0.000000000	0.200000000
w22	0.400000000	-0.000000000	0.000000000	0.400000000
b2	-0.100000000	-0.009634287	0.004817143	-0.095182857
v1	0.200000000	0.067606069	-0.033803034	0.166196966
v2	-0.300000000	0.061172501	-0.030586250	-0.330586250
by	0.100000000	0.128778570	-0.064389285	0.035610715

Instância 2 — x1 = 0, x2 = 1, alvo = 1

1. Propagação e saída

z1 = (0.100000000 × 0) + (0.300000000 × 1) + (0.096788571) = 0.396788571

h1 = σ(0.396788571) = 0.597915836

z2 = (0.200000000 × 0) + (0.400000000 × 1) + (-0.095182857) = 0.304817143

h2 = σ(0.304817143) = 0.575619683

zy = (0.166196966 × 0.597915836) + (-0.330586250 × 0.575619683) + (0.035610715) = -0.055309440

ŷ = σ(-0.055309440) = 0.486176164; classe = 0; alvo = 1.

Classificação incorreta: atualizar os pesos.

2. Derivadas da sigmoide

Neurônio	Cálculo: saída × (1 − saída)	Derivada
h1	0.597915836 × (1 – 0.597915836)	0.240412489
h2	0.575619683 × (1 – 0.575619683)	0.244281664
y	0.486176164 × (1 – 0.486176164)	0.249808902

3. Erros e deltas

erro_y = 1 – (0.486176164) = 0.513823836

δy = (0.513823836) × 0.249808902 = 0.128357768

erro_h1 = (0.128357768) × (0.166196966) = 0.021332672

δh1 = (0.021332672) × 0.240412489 = 0.005128641

erro_h2 = (0.128357768) × (-0.330586250) = -0.042433313

δh2 = (-0.042433313) × 0.244281664 = -0.010365680

Perda E = $(t - \hat{y})^2/2$ = 0.132007467.

4. Gradientes e pesos após a instância

Δ aplicado = –0,5 × gradiente se a classe estiver incorreta; caso contrário, Δ aplicado = 0.

Peso	Antes	∂E/∂peso	Δ aplicado	Depois
w11	0.100000000	-0.000000000	0.000000000	0.100000000
w21	0.300000000	-0.005128641	0.002564320	0.302564320
b1	0.096788571	-0.005128641	0.002564320	0.099352891
w12	0.200000000	0.000000000	-0.000000000	0.200000000
w22	0.400000000	0.010365680	-0.005182840	0.394817160
b2	-0.095182857	0.010365680	-0.005182840	-0.100365697
v1	0.166196966	-0.076747142	0.038373571	0.204570537
v2	-0.330586250	-0.073885258	0.036942629	-0.293643622
by	0.035610715	-0.128357768	0.064178884	0.099789599

Instância 3 — x1 = 1, x2 = 0, alvo = 1

1. Propagação e saída

z1 = (0.100000000 × 1) + (0.302564320 × 0) + (0.099352891) = 0.199352891

h1 = σ(0.199352891) = 0.549673822

z2 = (0.200000000 × 1) + (0.394817160 × 0) + (-0.100365697) = 0.099634303

h2 = σ(0.099634303) = 0.524887991

zy = (0.204570537 × 0.549673822) + (-0.293643622 × 0.524887991) + (0.099789599) = 0.058106657

ŷ = σ(0.058106657) = 0.514522578; classe = 1; alvo = 1.

Classificação correta: manter todos os pesos.

2. Derivadas da sigmoide

Neurônio	Cálculo: saída × (1 − saída)	Derivada
h1	0.549673822 × (1 – 0.549673822)	0.247532511
h2	0.524887991 × (1 – 0.524887991)	0.249380588
y	0.514522578 × (1 – 0.514522578)	0.249789095

3. Erros e deltas

erro_y = 1 – (0.514522578) = 0.485477422

δy = (0.485477422) × 0.249789095 = 0.121266966

erro_h1 = (0.121266966) × (0.204570537) = 0.024807648

δh1 = (0.024807648) × 0.247532511 = 0.006140699

erro_h2 = (0.121266966) × (-0.293643622) = -0.035609271

δh2 = (-0.035609271) × 0.249380588 = -0.008880261

Perda E = $(t - \hat{y})^2/2$ = 0.117844163.

4. Gradientes e pesos após a instância

Δ aplicado = –0,5 × gradiente se a classe estiver incorreta; caso contrário, Δ aplicado = 0.

Peso	Antes	∂E/∂peso	Δ aplicado	Depois
w11	0.100000000	-0.006140699	0.000000000	0.100000000
w21	0.302564320	-0.000000000	0.000000000	0.302564320
b1	0.099352891	-0.006140699	0.000000000	0.099352891
w12	0.200000000	0.008880261	0.000000000	0.200000000
w22	0.394817160	0.000000000	0.000000000	0.394817160
b2	-0.100365697	0.008880261	0.000000000	-0.100365697
v1	0.204570537	-0.066657276	0.000000000	0.204570537
v2	-0.293643622	-0.063651574	0.000000000	-0.293643622
by	0.099789599	-0.121266966	0.000000000	0.099789599

Instância 4 — x1 = 1, x2 = 1, alvo = 0

1. Propagação e saída

z1 = (0.100000000 × 1) + (0.302564320 × 1) + (0.099352891) = 0.501917212

h1 = σ(0.501917212) = 0.622909777

z2 = (0.200000000 × 1) + (0.394817160 × 1) + (-0.100365697) = 0.494451463

h2 = σ(0.494451463) = 0.621154521

zy = (0.204570537 × 0.622909777) + (-0.293643622 × 0.621154521) + (0.099789599) = 0.044820523

ŷ = σ(0.044820523) = 0.511203255; classe = 1; alvo = 0.

Classificação incorreta: atualizar os pesos.

2. Derivadas da sigmoide

Neurônio	Cálculo: saída × (1 − saída)	Derivada
h1	0.622909777 × (1 – 0.622909777)	0.234893187
h2	0.621154521 × (1 – 0.621154521)	0.235321582
y	0.511203255 × (1 – 0.511203255)	0.249874487

3. Erros e deltas

erro_y = 0 – (0.511203255) = -0.511203255

δy = (-0.511203255) × 0.249874487 = -0.127736651

erro_h1 = (-0.127736651) × (0.204570537) = -0.026131155

δh1 = (-0.026131155) × 0.234893187 = -0.006138030

erro_h2 = (-0.127736651) × (-0.293643622) = 0.037509053

δh2 = (0.037509053) × 0.235321582 = 0.008826690

Perda E = $(t - \hat{y})^2/2$ = 0.130664384.

4. Gradientes e pesos após a instância

Δ aplicado = –0,5 × gradiente se a classe estiver incorreta; caso contrário, Δ aplicado = 0.

Peso	Antes	∂E/∂peso	Δ aplicado	Depois
w11	0.100000000	0.006138030	-0.003069015	0.096930985
w21	0.302564320	0.006138030	-0.003069015	0.299495305
b1	0.099352891	0.006138030	-0.003069015	0.096283876
w12	0.200000000	-0.008826690	0.004413345	0.204413345
w22	0.394817160	-0.008826690	0.004413345	0.399230505
b2	-0.100365697	-0.008826690	0.004413345	-0.095952352
v1	0.204570537	0.079568409	-0.039784204	0.164786332
v2	-0.293643622	0.079344198	-0.039672099	-0.333315721
by	0.099789599	0.127736651	-0.063868326	0.035921274

Resumo da época

Entrada	Alvo	Saída antes do ajuste	Classe	Ajustou?
(0, 0)	0	0.515617317	1	Sim
(0, 1)	1	0.486176164	0	Sim
(1, 0)	1	0.514522578	1	Não
(1, 1)	0	0.511203255	1	Sim

As saídas acima são as obtidas durante o treinamento: cada instância recebe os pesos deixados pela anterior. Uma época não garante aprender o XOR. A tabela seguinte reavalia todas as entradas com os pesos finais, sem novos ajustes.

Entrada	Alvo	Saída com pesos finais	Classe
(0, 0)	0	0.490903394	0
(0, 1)	1	0.485671892	0
(1, 0)	1	0.487643170	0
(1, 1)	0	0.482540632	0

Observação: o SGD usual pode atualizar os pesos em todas as instâncias, mesmo quando a classe está correta. Esta resolução segue a restrição expressa da lista, atualizando apenas quando há erro de classificação.