# ETAPAS DE PRÉ-PROCESSAMENTO

## DADOS INCONSISTENTES E REDUNDANTES

Cristiane Neri Nobre

# Dados inconsistentes

- Dados **inconsistentes** são aqueles que possuem valores **conflitantes em seus atributos**

**Em que situação isso ocorre?**

- Dados inconsistentes são muitas vezes produzidos no processo de integração de dados (ex: diferentes conjuntos de dados podem usar escalas diferentes para uma mesma medida (metros e centímetros)

- Duas instâncias iguais com classificações diferentes

| Idade | Sexo | Peso | Manchas | Temp. | # Int. | Diagnóstico |
|---|---|---|---|---|---|---|
| 28 | M | 79 | Concentradas | 38,0 | 2 | Doente |
| 18 | F | 67 | Inexistentes | 39,5 | 4 | Doente |
| 49 | M | 92 | Espalhadas | 38,0 | 2 | Saudável |
| 18 | M | 43 | Inexistentes | 38,5 | 8 | Doente |
| 21 | F | 52 | Uniformes | 37,6 | 1 | Saudável |
| **22** | **F** | **72** | **Inexistentes** | **38,0** | **3** | **Doente** |
| 19 | F | 87 | Espalhadas | 39,0 | 6 | Doente |
| **22** | **F** | **72** | **Inexistentes** | **38,0** | **3** | **Saudável** |

# Dados redundantes

- Dados **redundantes** podem se referir tanto a **instâncias** quanto a **atributos**
  - Uma **instância é redundante** quando ela é **muito semelhante** a uma outra instância do mesmo conjunto de dados

| Sexo | Esco | Fetária | Renda | Area | GostaA | GostaB |
|---|---|---|---|---|---|---|
| F | 1 | 2 | 4 | 5 | S | N |
| F | 1 | 2 | 4 | 7 | S | S |

# Dados redundantes

- No caso extremo, instâncias da mesma base de dados podem ser literalmente iguais

| Idade | Sexo | Peso | Manchas | Temp. | # Int. | Diagnóstico |
|---|---|---|---|---|---|---|
| 28 | M | 79 | Concentradas | 38,0 | 2 | Doente |
| **18** | **F** | **67** | **Inexistentes** | **39,5** | **4** | **Doente** |
| 49 | M | 92 | Espalhadas | 38,0 | 2 | Saudável |
| **18** | **F** | **67** | **Inexistentes** | **39,5** | **4** | **Doente** |
| 18 | M | 43 | Inexistentes | 38,5 | 8 | Doente |
| 21 | F | 52 | Uniformes | 37,6 | 1 | Saudável |
| 22 | F | 72 | Inexistentes | 38,0 | 3 | Doente |
| 19 | F | 87 | Espalhadas | 39,0 | 6 | Doente |
| 34 | M | 67 | Uniformes | 38,4 | 2 | Saudável |

# Dados redundantes

- Um **atributo é redundante** quando seu valor para todas as instâncias pode ser deduzido a partir do valor de um ou mais atributos

| Data de Nascimento | Idade |
|---|---|
| 2010 | 10 |
| 2014 | 6 |
| 2007 | 13 |

| NumVendas | Valor por Venda | VendaTotal |
|---|---|---|
| 100 | 6 | 600 |
| 30 | 4 | 120 |
| 20 | 80 | 1600 |

# Dados redundantes

- No caso extremo, quando o atributo possui o mesmo valor que um outro atributo para cada uma das instâncias da base de dados

| Idade | Sexo | Peso | Manchas | Temp. | # Int. | # Vis. | Diagnóstico |
|---|---|---|---|---|---|---|---|
| 28 | M | 79 | Concentradas | 38,0 | 2 | **2** | Doente |
| 18 | F | 67 | Inexistentes | 39,5 | 4 | **4** | Doente |
| 49 | M | 92 | Espalhadas | 38,0 | 2 | **2** | Saudável |
| 18 | M | 43 | Inexistentes | 38,5 | 8 | **8** | Doente |
| 21 | F | 52 | Uniformes | 37,6 | 1 | **1** | Saudável |
| 22 | F | 72 | Inexistentes | 38,0 | 3 | **3** | Doente |
| 19 | F | 87 | Espalhadas | 39,0 | 6 | **6** | Doente |
| 34 | M | 67 | Uniformes | 38,4 | 2 | **2** | Saudável |

# Int = Número de internações

# Int = Número de vezes que o paciente esteve no hospital

# Dados redundantes

- A redundância de um atributo está relacionada à sua **correlação** com um ou mais atributos do conjunto de dados.

- Dois ou mais atributos estão correlacionados quando apresentam um perfil de variação semelhante para as diferentes instâncias.

| Aluno | Horas de Estudo | Nota |
|---|---|---|
| 1 | 20 | 9,5 |
| 2 | 12 | 2,5 |
| 3 | 14 | 3,6 |
| 4 | 15 | 6,7 |
| 5 | 18 | 5,2 |
| 6 | 9 | 1 |

Corr>0.90

# Dados redundantes

- Se a correlação ocorrer entre um atributo de entrada e um atributo de classificação, este atributo de entrada terá uma grande influência na predição do valor do atributo rótulo

| Quebrou regra do tipo | Quebrou regra? |
|---|---|
| A | Sim |
| B | Sim |
| Não quebrou regra | Não |
| C | Sim |
| Não quebrou regra | Não |

# Dados redundantes

**Qual a causa da redundância?**

- Problemas na coleta, na entrada, no armazenamento, na integração ou na transmissão de dados

**O fato é que bases reais têm muita redundância e inconsistência!**

# Dados redundantes e inconsistentes

**Investigue eliminação de redundância e inconsistência no código (está no CANVAS)**

Lendo_e_tratando_arquivo_IRIS.ipynb

AD_RF_Titanic_processamento

# Referências:

- Capítulo 3 do livro

