TRANSFORMAÇÃO DE DADOS
CONVERSÃO SIMBÓLICO-NUMÉRICO

Cristiane Neri Nobre

Conversão simbólico-Numérico

- Técnicas como redes neurais artificias, SVM e vários algoritmos de agrupamento lidam apenas com **dados numéricos**

- **E o que podemos fazer quando temos dados simbólicos (nominais/categóricos)?**

  - Precisamos transformar os valores para valores numéricos!

E como podemos fazer isso?

Conversão simbólico-Numérico

Caso 1:

Quando o atributo é do **tipo simbólico** e assume apenas dois valores, se os valores denotam a presença ou ausência de uma característica podemos utilizar **um dígito binário**

Exemplos

Gênero:

Masculino – 0

Feminino – 1

Tumor:

Maligno – 0

Benigno – 1

Conversão simbólico-Numérico

Caso 2:

Quando o atributo é do **tipo simbólico** e assume mais de dois valores, a técnica utilizada na conversão depende de o atributo ser **nominal ou ordinal**.

Se não houver uma relação de ordem entre os valores do atributo, a inexistência de uma relação de ordem deve continuar para os valores numéricos gerados.

Ou seja, a diferença entre quaisquer dois valores numéricos deve ser a mesma.

Uma forma de conseguir isso é codificar cada valor nominal por uma sequência de *c* bits, em que *c* é igual ao número de possíveis valores ou categorias.

Conversão simbólico-Numérico

Na codificação 1-de-c, também denominada canônica ou topológica, cada sequência possui apenas um bit com o valor 1 e os demais com o valor zero.

A diferença entre as sequências é definida pela posição que o valor 1 ocupa nelas.

Para definir a diferença entre dois valores, pode ser utilizada a distância de Hamming.

Conversão simbólico-Numérico

Nesta codificação, cada posição da sequência binária corresponde a um possível valor do atributo nominal.

Por exemplo, se a sequência binária possui 4 bits, o primeiro corresponde ao primeiro valor, o segundo bit ao segundo valor e assim por diante.

Como apenas um dos bits pode assumir o valor 1, o bit que assumir esse valor sinaliza a presença do valor nominal correspondente àquele bit.

Conversão simbólico-Numérico

Exemplo de codificação 1-de-*c*

Atributo nominal	Código $1-de-c$
Azul	100000
Amarelo	010000
Verde	001000
Preto	000100
Marrom	000010
Branco	000001

Observem que são utilizados 6 bits! Não é um número inteiro!

Isso é o chamo de **binarizar o atributo.**

O que significa isso?

Que um único atributo com 6 opções de resposta vão virar 6 entradas na base de dados.

Conversão simbólico-Numérico

É como se você enxergasse:

Azul	Amarelo	Verde	Preto	Marrom	Branco
1	0	0	0	0	0
0	**1**	0	0	0	0
0	0	**1**	0	0	0
0	0	0	**1**	0	0
0	0	0	0	**1**	0
0	0	0	0	0	**1**

Observem que são utilizados 6 bits! Não é um número inteiro!

Isso é o que chamo de **binarizar o atributo.**

O que significa isso?

Que um único atributo com 6 opções de resposta vão virar 6 entradas na base de dados.

Conversão simbólico-Numérico

É como se você enxergasse:

Azul	Amarelo	Verde	Preto	Marrom	Branco
1	0	0	0	0	0
0	**1**	0	0	0	0
0	0	**1**	0	0	0
0	0	0	**1**	0	0
0	0	0	0	**1**	0
0	0	0	0	0	**1**

E veja que a distância de Hamming entre as instâncias é sempre 2.

Conversão simbólico-Numérico

Onde mais podemos utilizar esta codificação?

Em vários outros contextos!

Exemplo:
Onde você nasceu?

- ○ Em casa
- ○ no hospital
- ○ na rua
- ○ na BR

Instância	Em casa	No Hosp	Na rua	Na BR
1	**1**	0	0	0
2	0	**1**	0	0
3	0	0	**1**	0
4	0	0	0	**1**

Conversão simbólico-Numérico

Exemplo:

Qual o seu curso?

- CC
- SI
- Jogos
- ES

Instância	CC	SI	Jogos	ES
1	**1**	0	0	0
2	0	**1**	0	0
3	0	0	**1**	0
4	0	0	0	**1**

Conversão simbólico-Numérico

Veja que isso é interessante apenas para atributos com poucas opções de resposta.

Imagina se você tiver que criar uma codificação desta para representar 193 países?

Isso não seria uma boa opção!

Conversão simbólico-Numérico

Uma alternativa é a representação dos possíveis valores nominais por um conjunto de pseudoatributos.

Os valores dos pseudoatributos podem ser do tipo binário, inteiro ou real

Pseudoatributo e seus possíveis valores

Pseudoatributo	#Valores
Continente	7 (b)
PIB	1 (i)
População	1 (i)
TMA	1 (i)
Área	1 (i)

Conversão simbólico-Numérico

Onde mais podemos ver este tipo de atributos?

1) Qual a cidade onde você mora?
2) Qual o curso você faz (com muitas opções de resposta)?
3) Qual o tipo de droga você já utilizou?

Conversão simbólico-Numérico

Caso 3:

Quando existe uma relação de ordem, o atributo é do tipo ordinal, e a codificação deve preservar essa relação.

Para isso, deve ser utilizada uma codificação em que a ordem dos valores esteja clara.

Conversão simbólico-Numérico

Quando o valor numérico é um número **inteiro ou real**, essa transformação é simples e direta: basta ordenar os valores categóricos ordinais e codificar cada valor de acordo com sua posição na ordem:

Valor ordinal	Valor inteiro
Primeiro	0
Segundo	1
Terceiro	2
Quarto	3
Quinto	4
Sexto	5

Conversão simbólico-Numérico

Se for necessário converter valores ordinais em valores binários, pode ser utilizado o **código cinza** ou o **código termômetro**.

Valor ordinal	Código cinza	Código termômetro
Primeiro	000	00000
Segundo	001	00001
Terceiro	011	00011
Quarto	010	00111
Quinto	110	01111
Sexto	100	11111

Codificação em Python

Veja os comandos **One-Hot Encoding e Label Encoding** na codificação da base de dados **Restaurante**, vista em sala e que está no CANVAS.

AD_Restaurante_codifica_treina_e_avalia.ipynb

Veja também o exemplo sobre o **Titanic** que está no CANVAS:

AD_RF_Titanic_processamento.ipynb

Referências:

- Capítulo 3 do livro (Seção 3.6.1)

