TRANSFORMAÇÃO DE DADOS
REDUÇÃO DE DIMENSIONALIDADE

Cristiane Neri Nobre

Redução de dimensionalidade

- Muitos problemas que podem ser tratados por técnicas de AM apresentam um número elevado de atributos.

- Poucas técnicas de AM podem lidar com um número tão grande de atributos

- O efeito do número muito grande de atributos em algoritmos de AM é descrito como problema da **maldição de dimensionalidade**

Redução de dimensionalidade

- Suponha conjunto de dados em que cada instância possui apenas **um atributo** e que esse atributo pode assumir um dentre **10 valores**

- Esse conjunto de dados pode ter então 10^1 ou 10 instâncias diferentes, um para cada valor diferente do atributo

- Se o número de atributos passar para 5, o número de possíveis instâncias passa a ser 10^5, que é um número de possíveis **instâncias muito maior** do que quando apenas um atributo foi utilizado.

Redução de dimensionalidade

- Uma forma de minimizar o impacto do problema da dimensionalidade é **combinar ou eliminar** parte dos atributos irrelevantes

- A redução do número de atributos pode ainda melhorar o **desempenho** do modelo induzido, reduzir seu **custo computacional** e tornar os resultados obtidos mais **compreensíveis**

Redução de dimensionalidade

As abordagens utilizadas para resolver este problema podem ser divididas em:

- **Agregação**
  - Substituem os atributos originais por novos atributos formados pela combinação de grupos de atributos
  - Levam à perda dos valores originais dos atributos, o que pode ser importante dependendo do contexto (finanças, saúde, etc)

- **Seleção de atributos**
  - Mantem uma parte dos atributos originais e descartam os demais atributos

Redução de dimensionalidade

- **Seleção de atributos** permite:

- Identificar atributos importantes
- Melhorar o desempenho de várias técnicas de AM
- Reduzir a necessidade de memória e tempo de processamento
- Eliminar atributos irrelevantes e reduzir ruído
- Lidar com a maldição da dimensionalidade
- Simplificar o modelo gerado e tornar mais fácil a sua compreensão
- Facilitar a visualização dos dados
- Reduzir o custo de coleta de dados e com isso aumentar acesso a novas tecnologias

Redução de dimensionalidade

Três abordagens são utilizadas para avaliar a qualidade ou desempenho de um subconjunto de atributos:

- **Embutida**
- **Baseada em Filtro**
- **Baseada em Wrapper**

Redução de dimensionalidade

- **Embutida**
  - Nesta abordagem a seleção do subconjunto é embutida ou integrada no próprio algoritmo de aprendizado (ex: Árvore de decisão)

- **Baseada em Filtro**
  - Nesta abordagem, em uma etapa de pré-processamento, é utilizado um filtro sobre o conjunto de atributos original que filtra um subconjunto de atributos do conjunto original, sem levar em consideração o algoritmo de aprendizado que utilizará esse subconjunto (Ex: correlação)

- **Baseada em Wrapper**
  - Utiliza o próprio algoritmo de aprendizado como uma caixa-preta para a seleção;
  - Geralmente é utilizado junto com uma técnica de amostragem;
  - Para cada possível subconjunto, o algoritmo é consultado e o subconjunto que apresentar a melhor combinação entre redução da taxa de erro e redução do número de atributos é em geral selecionado

Redução de dimensionalidade

Vantagens das abordagens baseadas em Filtro:

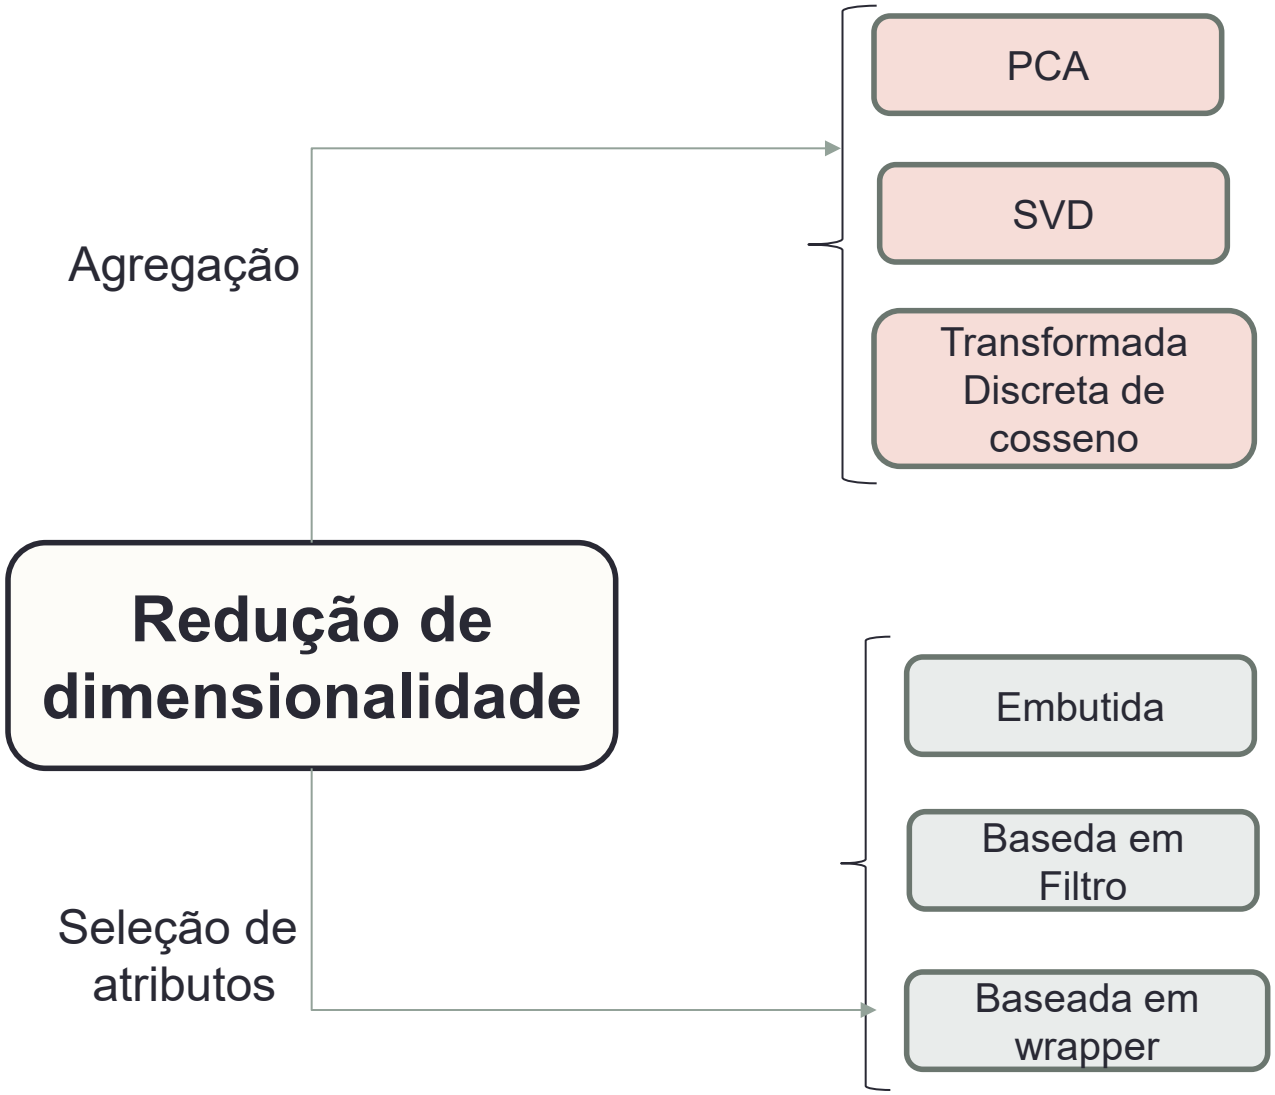
- Como o processo de seleção não depende de nenhum indutor, as características selecionadas podem ser utilizadas por diferentes algoritmos de AM;
- As heurísticas utilizadas para avaliar um subconjunto são computacionalmente pouco custosas, assim os filtros podem ser bastante rápidos
- Os filtros conseguem lidar eficientemente com uma grande quantidade de dados

Redução de dimensionalidade

Vantagens das abordagens baseadas em Wrapper:

- Podem ser muito eficientes (quanto às métricas de avaliação), apesar do tempo computacional
- É uma alternativa simples

Redução de dimensionalidade



Adaptado de Gollapudi Sunila. Practical Machine Learning. 2016

Mais informações sobre Redução de dimensionalidade

- Se desejarem saber mais informações sobre **redução de dimensionalidade**, veja o artigo abaixo

- **Artigo:** Prediction of enzymatic function with high efficiency and a reduced number of features using genetic algorithm

- **Link:** https://www.sciencedirect.com/science/article/abs/pii/S0010482523002640

Referências:

Capítulo 3 do livro

