ETAPAS DE PRÉ-PROCESSAMENTO

SELEÇÃO DE INSTÂNCIAS

Cristiane Neri Nobre

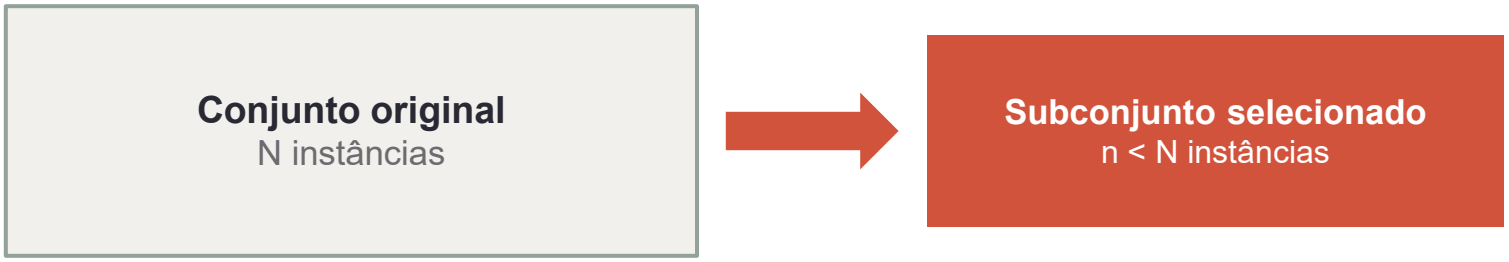
Seleção de instâncias

- Bases de dados reais podem conter um número muito grande de instâncias
- Isso aumenta o custo computacional (tempo e memória) necessário para treinar e utilizar os modelos de Aprendizado de Máquina
- Nem todas as instâncias contribuem da mesma forma para o aprendizado: algumas são redundantes, ruidosas ou pouco informativas



O que é seleção de instâncias?

- É o processo de escolher um subconjunto representativo das instâncias originais, descartando as consideradas redundantes, ruidosas ou pouco úteis para o aprendizado
- O objetivo é manter — ou até melhorar — o desempenho do modelo, usando um conjunto de dados menor



Seleção de instâncias x etapas já vistas

É importante não confundir a seleção de instâncias com outras etapas de pré-processamento já vistas:

Etapa	O que faz
Balanceamento (Parte 1)	Altera a proporção entre classes (oversampling / undersampling)
Dados redundantes e inconsistentes (Parte 3)	Remove apenas duplicatas exatas ou instâncias com classes conflitantes
Seleção de instâncias (esta parte)	Pode remover qualquer instância considerada pouco útil, ruidosa ou redundante em comportamento, mesmo sem ser uma duplicata exata

Benefícios da seleção de instâncias

- Reduz o tempo e o custo computacional de treinamento
- Reduz a necessidade de memória e armazenamento
- Pode remover ruído e outliers, melhorando a capacidade de generalização do modelo
- É especialmente importante para algoritmos baseados em instâncias (ex.: k-NN), cujo custo cresce com o tamanho da base
- Facilita a análise e a visualização dos dados

Abordagens para seleção de instâncias

Assim como na seleção de atributos (Parte 7), a qualidade de um subconjunto de instâncias pode ser avaliada de três formas:

Filtro

Usa um critério independente do algoritmo de aprendizado (ex.: distância ou densidade entre instâncias)

Wrapper

Usa o próprio algoritmo de aprendizado para avaliar o impacto de manter ou remover cada instância

Embutida

O mecanismo de seleção já está incorporado ao próprio algoritmo de aprendizagem

Principais técnicas de seleção de instâncias

- Amostragem aleatória ou estratificada
- Condensed Nearest Neighbor (CNN)
- Edited Nearest Neighbor (ENN)
- Tomek Links (também usado para balanceamento — Parte 1)
- Seleção baseada em agrupamento (clustering): mantém instâncias representativas de cada grupo

Condensed Nearest Neighbor (CNN)

Como funciona?

- Parte de um subconjunto pequeno (ex.: uma instância de cada classe) e vai incorporando, uma a uma, as instâncias do conjunto original que seriam classificadas incorretamente pelo subconjunto atual (usando 1-NN)
- O processo se repete até que todas as instâncias do conjunto original sejam corretamente classificadas pelo subconjunto formado

Objetivo

- Obter um subconjunto mínimo e consistente: pequeno, mas ainda capaz de classificar corretamente as instâncias descartadas

Exemplo numérico: CNN

Conjunto original com 6 instâncias (2 atributos, 2 classes):

Instância	X1	X2	Classe
A	1	1	0
B	1	2	0
C	4	4	0
D	5	5	1
E	5	6	1
F	6	5	1

Passo 1: parte-se de S = {A, D} (uma instância de cada classe)

- B e demais instâncias próximas de A são classificadas corretamente por S → não entram

Passo 2: instância C = (4, 4), classe 0

- d(C, A) = 4,24 e d(C, D) = 1,41 → mais perto de D → 1-NN prevê classe 1, mas C é classe 0 → classificação errada → C é adicionada a S

Resultado: S = {A, C, D} - 3 de 6 instâncias mantidas

Edited Nearest Neighbor (ENN)

Como funciona?

- Para cada instância, verifica-se a classe da maioria dos seus k vizinhos mais próximos
- Se a classe da instância for diferente da classe majoritária entre seus vizinhos, ela é removida do conjunto

Objetivo

- Eliminar ruído e instâncias que estão na fronteira entre classes, deixando as regiões de decisão mais limpas

CNN x ENN

- CNN busca reduzir o tamanho da base; ENN busca reduzir o ruído - as duas técnicas são frequentemente usadas em conjunto

Exemplo numérico: ENN

Conjunto original com 7 instâncias (k = 3 vizinhos):

Instância	X1	X2	Classe
P1	1	1	0
P2	1	2	0
P3	2	1	0
P4	**2**	**2**	**1**
P5	5	5	1
P6	5	6	1
P7	6	5	1

Analisando P4 = (2, 2), classe 1

- 3 vizinhos mais próximos: P2 (d=1,0), P3 (d=1,0) e P1 (d=1,41) — todos classe 0
- Classe majoritária dos vizinhos = 0, mas P4 é classe 1 → P4 é removida (ruído)

Contraste: P1 = (1, 1), classe 0

- 3 vizinhos mais próximos: P2, P3 (classe 0) e P4 (classe 1) → maioria = classe 0 = classe de P1 → P1 é mantida

Seleção de instâncias em Python

```
pip install imbalanced-learn

from imblearn.under_sampling import CondensedNearestNeighbour, EditedNearestNeighbours

base = pd.read_csv('/content/sample_data/cancer.csv', sep=';')
#processa base
#Incluir aqui todas as etapas de pré-processamento

#Dividir em conjunto de treino e teste
X_treino, X_teste, y_treino, y_teste = train_test_split(
    X_prev, y_classe, test_size=0.20, random_state=42)

#Seleção de instâncias com CNN (feita apenas no treino)
cnn = CondensedNearestNeighbour(random_state=42)
X_cnn, y_cnn = cnn.fit_resample(X_treino, y_treino)

#Seleção de instâncias com ENN (feita apenas no treino)
enn = EditedNearestNeighbours()
X_enn, y_enn = enn.fit_resample(X_treino, y_treino)

#agora é só treinar o modelo com os arquivos gerados
#e testar com o arquivo de teste original
```

Exercício prático

- Utilizando a base de dados do Titanic (mesma base já trabalhada em atividades anteriores da disciplina):
- 1. Aplique a técnica CNN no conjunto de treino já pré-processado (após imputação, remoção de redundância/inconsistência e normalização) e anote quantas instâncias restaram
- 2. Aplique a técnica ENN no mesmo conjunto de treino e anote quantas instâncias restaram
- 3. Treine uma Árvore de Decisão e um Random Forest em três versões do treino: (a) original, (b) reduzido por CNN, (c) reduzido por ENN
- 4. Compare o F1-score dos três cenários no mesmo conjunto de teste (original, sem alterações)

Pergunta para reflexão

- A seleção de instâncias melhorou, piorou ou manteve o desempenho do modelo? A resposta foi igual para CNN e para ENN? Por quê isso pode ter acontecido?

Seleção de instâncias — Cuidado importante

- Assim como no balanceamento (Parte 1), a seleção de instâncias deve ser feita apenas no conjunto de treino
- Fazer a seleção de instâncias no conjunto completo (antes do split) causa vazamento de dados (data leakage)
- Ou seja: primeiro divida em treino e teste (train_test_split) e só depois aplique a técnica de seleção de instâncias - apenas sobre o conjunto de treino
- O conjunto de teste deve permanecer intacto, representando a distribuição real dos dados

Mais informações sobre Seleção de Instâncias

- Se desejarem se aprofundar no tema, um dos trabalhos de referência mais citados na área é:

- Wilson, D. R.; Martinez, T. R. Reduction Techniques for Instance-Based Learning Algorithms. Machine Learning, v. 38, p. 257–286, 2000.

Para saber mais, investigue a dissertação de mestrado da minha aluna sobre este tema:

Título: ANTIFS e RANTIFS – Métodos para Seleção de Instâncias e de Atributos com Controle de Probabilidade de Seleção

Ariane Carla Barbosa da Silva

Link:
https://bib.pucminas.br/teses/Informatica_ArianeCarlaBarbosaDaSilva_31375_TextoCompleto.pdf

Referências

- Wilson, D. R.; Martinez, T. R. Reduction Techniques for Instance-Based Learning Algorithms. Machine Learning, v. 38, p. 257–286, 2000.
- Hart, P. E. The Condensed Nearest Neighbor Rule. IEEE Transactions on Information Theory, v. 14, n. 3, p. 515–516, 1968.