ETAPAS DE PRÉ-PROCESSAMENTO

ELIMINAÇÃO DE OUTLIERS

Cristiane Neri Nobre

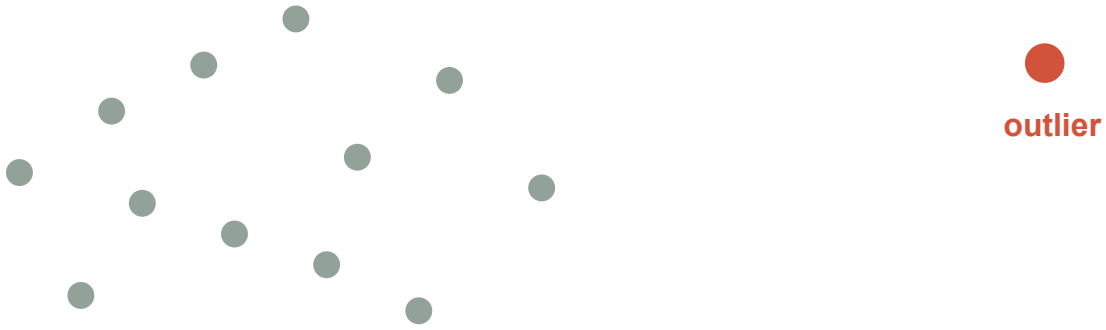
Eliminação de outliers

- Bases de dados reais podem conter valores muito distantes do padrão observado nas demais instâncias
- Esses valores podem indicar erros de coleta, digitação ou transmissão, ou eventos raros, porém genuínos
- Muitos algoritmos de AM (especialmente os baseados em distância ou em médias) são sensíveis a esses valores extremos, que podem distorcer o modelo aprendido



O que é um outlier?

- É uma instância cujo valor, para um ou mais atributos, está muito distante dos valores observados nas demais instâncias do conjunto de dados
- Também chamado de valor atípico, valor extremo ou anomalia



No exemplo, vemos instâncias próximas entre si (padrão típico) e uma instância isolada e muito distante das demais (outlier)

Outlier: erro ou informação genuína?

Nem todo outlier deve ser eliminado! É preciso investigar a causa antes de decidir:

Situação	Exemplo	O que fazer?
Erro de coleta, digitação ou medição	Idade = 200 anos	Corrigir (quando possível) ou eliminar a instância, ou ausentar o valor e depois imputar
Evento raro, porém real	Salário do CEO em uma base de funcionários	Avaliar com cautela, pode conter informação relevante

Eliminar um outlier que na verdade era um evento raro e real pode fazer o modelo perder informação importante

Tipos de outliers

Quanto ao número de atributos analisados

- Univariado: valor extremo em um único atributo, considerado isoladamente (ex.: idade = 200)
- Multivariado: combinação de valores atípica, mesmo que cada atributo pareça normal isoladamente (ex.: idade = 5 anos e escolaridade = doutorado)

Quanto ao contexto

- Global: é extremo em relação a todo o conjunto de dados
- Contextual: só é considerado atípico dentro de um contexto específico (ex.: 30°C é normal no verão, mas atípico no inverno)

Como detectar outliers?

- Métodos estatísticos: Z-score, Intervalo Interquartil (IQR / boxplot)
- Métodos baseados em distância: distância aos k vizinhos mais próximos
- Métodos baseados em densidade: Local Outlier Factor (LOF)
- Métodos baseados em isolamento: Isolation Forest
- Visualização: boxplot, histograma, gráfico de dispersão

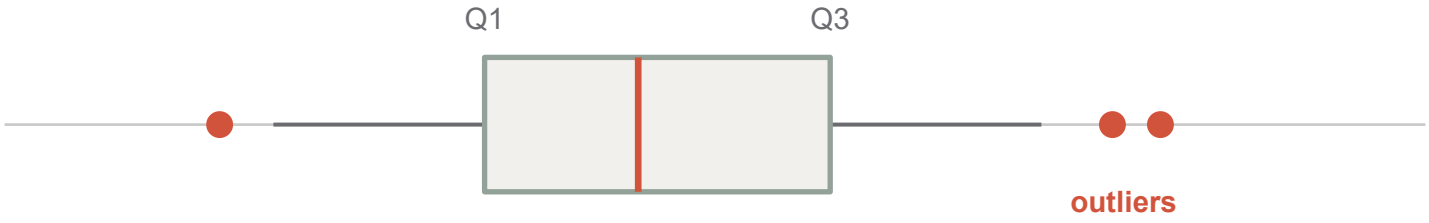
Métodos estatísticos: Z-score e IQR

Z-score

- Mede quantos desvios-padrão um valor está distante da média: Z = (x − média) / desvio-padrão
- Valores com |Z| acima de um limiar (em geral, 3) são considerados outliers

Intervalo Interquartil (IQR)

- IQR = Q3 − Q1 (diferença entre o 3º e o 1º quartil)
- São considerados outliers os valores abaixo de Q1 − 1,5×IQR ou acima de Q3 + 1,5×IQR



Exemplo prático

Salários (em milhares de R$) de uma equipe de 7 funcionários:

Funcionário	Cargo	Salário (R$ mil)
1	Analista	4,2
2	Analista	4,8
3	Analista Sênior	6,5
4	Analista	5,1
5	**Diretor(a) Geral**	**48,0**
6	Analista Sênior	7,0
7	Analista	4,5

- Média dos salários (com o outlier): R$ 11,4 mil — não representa bem o grupo
- Média dos salários (sem o outlier): R$ 5,35 mil — mais próxima da realidade da equipe
- O salário do funcionário 5 é um outlier: pode ser um evento genuíno (cargo de direção) — não deve ser tratado como erro sem investigação

LOF e Isolation Forest

Local Outlier Factor (LOF)

- Compara a densidade local de uma instância com a densidade de seus vizinhos mais próximos
- Uma instância com densidade muito menor que a de seus vizinhos é considerada um outlier

Isolation Forest

- Constrói árvores que isolam instâncias por meio de divisões aleatórias dos atributos
- Outliers tendem a ser isolados com menos divisões (mais rapidamente) do que instâncias normais

Eliminação de outliers x etapas já vistas

A eliminação de outliers também não deve ser confundida com outras etapas já vistas:

Etapa	O que faz
Dados redundantes e inconsistentes (Parte 3)	Remove duplicatas exatas ou instâncias com classes conflitantes
Seleção de instâncias (Parte 8)	Remove instâncias pouco úteis ou redundantes em comportamento, buscando reduzir o tamanho da base
Eliminação de outliers (esta parte)	Remove (ou trata) especificamente instâncias com valores extremos, muito distantes do padrão dos dados

Eliminação de outliers em Python

```
import numpy as np
from scipy import stats
from sklearn.ensemble import IsolationForest

#Dividir em conjunto de treino e teste
X_treino, X_teste, y_treino, y_teste = train_test_split(
    X_prev, y_classe, test_size=0.20, random_state=42)

#1. Método Z-score (feito apenas no treino)
z_scores = np.abs(stats.zscore(X_treino['salario']))
X_treino_zscore = X_treino[z_scores < 3]

#2. Método IQR (feito apenas no treino)
Q1 = X_treino['salario'].quantile(0.25)
Q3 = X_treino['salario'].quantile(0.75)
IQR = Q3 - Q1
limite_inf = Q1 - 1.5 * IQR
limite_sup = Q3 + 1.5 * IQR
X_treino_iqr = X_treino[
    (X_treino['salario'] >= limite_inf) &
    (X_treino['salario'] <= limite_sup)]

#3. Isolation Forest (feito apenas no treino)
iso = IsolationForest(contamination=0.05, random_state=42)
outlier_pred = iso.fit_predict(X_treino)
X_treino_iso = X_treino[outlier_pred == 1]  #1 = normal, -1 = outlier
```

Eliminação de outliers — Cuidados importantes

- Assim como nas demais etapas, os parâmetros de detecção (média, desvio-padrão, quartis) devem ser calculados apenas com o conjunto de treino, após o split, para evitar vazamento de dados
- O conjunto de teste deve permanecer intacto, representando a distribuição real dos dados; inclusive seus eventuais outliers
- Investigue a causa do outlier antes de eliminá-lo: pode ser um erro (eliminar) ou um evento raro, porém real (avaliar com cautela)
- O limiar escolhido (ex.: Z > 3, ou o multiplicador do IQR) impacta diretamente quantas instâncias serão eliminadas. **Não existe um valor universalmente correto**

Mais informações sobre Eliminação de Outliers

- Se desejarem se aprofundar no tema, dois dos trabalhos de referência mais citados na área são:

- Breunig, M. M. et al. LOF: Identifying Density-Based Local Outliers. ACM SIGMOD Record, v. 29, n. 2, p. 93–104, 2000.

- Liu, F. T.; Ting, K. M.; Zhou, Z.-H. Isolation Forest. In: IEEE International Conference on Data Mining (ICDM), 2008.

Referências

- Breunig, M. M. et al. LOF: Identifying Density-Based Local Outliers. ACM SIGMOD Record, v. 29, n. 2, p. 93–104, 2000.
- Liu, F. T.; Ting, K. M.; Zhou, Z.-H. Isolation Forest. In: IEEE International Conference on Data Mining (ICDM), 2008.